

个人简历

个人信息



熊宇

2028届应届生 | 本科 | 23岁 | 男

联系电话: 19113550207

电子邮箱: 927421812@qq.com

个人网站: www.yuuuxion.xyz (里面有我的部署项目和个人博客)

2025.09 - 至今

长安大学

软件工程专业硕士 (085405)

- **专业成绩:** GPA 3.62 (6 / 44)
- **研究方向:** 视觉语言模型因果可解释性, 关注跨模态表征、注意力机制与模型压缩。

2021.09 - 2025.06

西安工业大学

软件工程

- **专业成绩:** GPA 3.68 (2 / 235)
- **主修课程:** 软件工程, 设计模式, C语言程序设计, 面向对象技术与Java语言, 算法与数据结构, 数字电子技术, 数据库原理与应用, 计算机网络, 操作系统, LINUX操作系统。

研究经历

2026.07

基于机理可解释性的 VLM 结构化压缩与视觉 Token 剪枝

详细的实验报告见个人博客: <https://blog.yuuuxion.xyz/blog/personal/vlm实验报告一/>
<https://blog.yuuuxion.xyz/blog/personal/vlm实验报告二/>

围绕 Qwen3-VL-4B-Instruct 开展跨模态注意力头功能分析, 探索通过结构化剪枝和视觉 Token 选择降低模型资源开销, 建立从回路筛查、因果消融、真实结构压缩到恢复训练的实验流程。

- **技术栈:** Python + PyTorch + Transformers + Qwen3-VL + LoRA + GQA / VQAv2
- **研究工作:**
 - a. 结合 Attention Rollout、视觉与纯文本条件下的单头消融及 KL 散度分析, 构建覆盖 36 层、1,152 个注意力头的跨模态功能图谱; 第二轮引入同布局真实图像与 FFT 内容破坏图对照、EOS 停止行为检查, 分析筛选指标的适用边界。
 - b. 实现 Q/O 投影结构化剪枝, 删除指定 Query Head 对应的矩阵维度, 保留 K/V 投影及 GQA 分组映射; 通过固定样本上的动态消融与紧凑模型对照, 验证结构修改的功能一致性。
 - c. 第一轮在三个 VQAv2 评估种子下, 删除 105 个注意力头、减少约 6,881 万参数, 共识分数平均提升 4.27 个百分点; 第二轮筛选协议得到不同结果, 进一步确认注意力功能分类不能直接等同于剪枝安全性。
 - d. 探索基于回路 Rollout 的 2×2 空间 Block 视觉 Token 选择, 同步调整多模态嵌入、Mask、DeepStack 与 M-RoPE 位置; 在固定 1,000 题上, 实际保留 79.71% 视觉 Token, KV Cache 减少 13.65%, 共识分数相对完整模型下降 0.72 个百分点。
 - e. 开展 LoRA 答案监督恢复训练 Pilot, 300 步训练后压缩模型共识分数由 57.82% 提升至 72.54%; 通过匹配微调对照及配对 Bootstrap 分析恢复效果, 并分别测量参数量、显存、评分器开销和推理耗时。

这段适合 VLM 方向简历。第一轮的精度提升应保留“对应实验条件”的限定; 两轮目前都不能概括成“实现无损压缩或端到端加速”。Java + Agent 版则保留前两项, 压缩为两三行即可。

技能特长

- **模型实验:** Python、PyTorch、Transformers; 理解 Transformer、GQA、KV Cache、视觉编码与 M-RoPE, 开展推理、结构修改和评估。
- **可解释性与压缩:** Attention Rollout、Head 输出消融、KL 分析、Q/O 结构化剪枝、视觉 Token / Block 选择; 区分相关性、因果干预和部署收益。
- **训练与评估:** LoRA、Answer-only SFT、VQAv2 共识评分、层匹配随机对照、配对及图像簇 Bootstrap, 具备训练 / 评估样本隔离经验。
- **工程基础:** C/C++、Java、Linux、多线程、Git; 具备模型 API 接入、应用联调、云部署与底层接口调试经验。

项目经历

Vibe Music 音乐站与 AI 助手

2026.09

项目部署地址（可访问）：<https://music.yuuuxion.xyz/>

项目开源地址：<https://github.com/anyayuqiu/vibe-music>

详细的项目文档见个人博客：<https://blog.yuuuxion.xyz/blog/personal/vibe-music-项目文档/>

- 本项目采用前后端分离架构，包含用户端、管理端和服务端，提供歌曲、歌手及歌单资料展示、搜索、收藏、评论和后台内容管理功能。集成 AI 音乐资料助手，通过工具调用查询站内曲库，以流式文字和推荐卡片展示结果，完成云服务器部署及 HTTPS 访问。
- 技术栈：Java 17 + Spring Boot 3 + MySQL + Redis + MinIO + LangChain4j + Docker Compose + Caddy
- 项目职责：
 - a. 完成用户端、管理端与服务端的功能调整及接口联调，使用 MySQL 存储业务数据、MinIO 管理封面和头像，支持音乐资料展示与后台维护。
 - b. 基于 LangChain4j 集成大模型，封装关键词搜索、风格推荐等曲库查询工具，实现多轮对话与基于真实业务数据的歌曲推荐。
 - c. 使用 SSE 实现回答流式输出，解析模型返回的歌曲 ID，由服务端校验并回查数据库生成推荐卡片，将正文与结构化结果分开发送。
 - d. 完善 JWT 身份认证、管理员初始化及跨域配置，结合 Redis 和 Semaphore 实现调用间隔、每日额度及并发限制。
 - e. 使用 Docker Compose 在云服务器编排 Java、MySQL、Redis 和 MinIO，通过 Caddy 配置 HTTPS、接口反向代理和图片访问，完成部署与运行问题排查。

GalSpace2 本地游戏管理工具

2026.05

项目开源地址：<https://github.com/anyayuqiu/GalSpace2>

详细的项目文档见个人博客：<https://blog.yuuuxion.xyz/blog/personal/galspace2-项目文档/>

本项目是一款面向 Windows 的本地游戏库管理工具，集成了目录扫描、手动导入、分类标签、收藏及详情编辑，并支持 VNDB 元数据检索和 DeepSeek 翻译，能够提供本地游戏库管理、批量导入、元数据获取与 AI 翻译等功能。

- 技术栈：Java 17 + Spring Boot + VNDB REST API + JSON 文件存储 + Node.js + Electron
- 项目职责：
 - a. 独立完成游戏库核心业务开发，实现目录扫描、手动导入、分类标签、收藏及详情编辑，并使用 JSON 文件存储业务数据。
 - b. 对接 VNDB REST API 获取游戏标题、简介、评分和截图；实现批量检索与导入，通过 6 线程并行处理并汇总成功、失败结果。
 - c. 接入 Chat Completions API 翻译简介及标签，支持 API Key 配置和原始文本标记清理，将模型能力接入业务流程。
 - d. 实现游戏、分类和配置持久化及关联管理，提供局域网访问、端口配置与精简 JRE 打包方式。

实习经历

2024.07-2024.09

华勤技术股份有限公司

驱动开发工程师

- 工作描述：我负责在 RTOS（FreeRTOS）环境中进行传感器驱动的移植和开发工作，实现传感器驱动程序，确保其在 RTOS 环境下稳定运行，并输出了 sensor 驱动调试指南及驱动开发流程的总结文档。
- 实习项目：实习期间我参与了基于恒玄 BES2700iH 平台的智能戒指项目，本项目是一款集成了温度计、A+G、PPG，并支持蓝牙和 NFC 功能的智能戒指。它能够提供包括心率监测、体温测量、活动检测在内的健康监测功能。
- 技术栈：C + FreeRTOS + makefile + I2C + SPI
- 项目职责：
 - a. 参与了智能戒指项目的 sensor 驱动开发，深入理解了驱动开发流程和常见 sensor 的校准原理。
 - b. 负责温度计 CT7117 和 A+G (BMI270) 的初始化和调试工作。
 - c. 实现了 CT7117 温度计与 BES2700iH 平台之间的 I2C 通信，并成功移植了温度数据的读写接口。
 - d. 通过 SPI 完成了 BMI270 的初始化和调试，并利用平台底层接口移植了 BMI270 的初始化及数据读取接口。

获奖情况

详细的获奖信息和证件图片见个人博客：<https://blog.yuuuxion.xyz/blog/personal/简历支撑材料/>

- 竞赛成绩：
 - CFF 智能汽车大赛自动驾驶仿真赛 全国决赛 第七名
 - 全国大学生信息安全与对抗技术竞赛智能安全赛 总决赛 优秀奖
 - 全国大学生数学竞赛 初赛 三等奖、蓝桥杯 C/C++ 组 区域赛 二等奖
- 持有证书：软件设计师中级 日语四六级